

# Omówienie projektów

Mateusz Doliński, Katarzyna Głowacka, Michał Kozyra

Optymalizacja I - rok 2016/2017

21.06.2017

# Pivot Rules - Projekt 1

Mateusz Doliński, Katarzyna Głowacka, Michał Kozyra

Optymalizacja I - rok 2016/2017

21.06.2017

# Nasze zadanie

- ▶ zaimplementowanie 11 metod wyboru zmiennych (tj. wierzchołków) w algorytmie sympleks
- ▶ przetestowanie metod na 14 problemach testowych  $LP0-LP13$ : odpowiedź na pytanie, ile kroków potrzeba do znalezienia optymalnego wierzchołka dla każdej pary metoda-problem
- ▶ zbadanie, jak dana reguła wyboru zmiennych wchodzących/wychodzących wpływa na liczbę kroków algorytmu sympleks

## Użytkowanie kodu

- ▶ kod programu uruchamiamy w Sage
- ▶ w linii 1154 zmieniamy aktualny wybór zakresu metod (0-10) i poddawanych testom problemów LP (0-13)

# Użyte funkcje pivot

- ▶ *smallest\_coefficient* vs *largest\_coefficient*
  - ▶ wybór zmiennej wchodzącej o najmniejszym/największym współczynniku funkcji celu;
- ▶ *smallest\_increase* vs *largest\_increase*
  - ▶ wybór zmiennej, który prowadzi do najmniejszego/największego wzrostu funkcji celu;
- ▶ *lexicographical\_max* vs *lexicographical\_min*
  - ▶ wybór zmiennej wchodzącej i wychodzącej pierwszej/ostatniej słownikowo;
- ▶ *steepest\_edge* vs *flattest\_edge*
  - ▶ wybór zmiennej, który prowadzi do wierzchołka w kierunku najbliższym/najdalszym wektorowi  $c$  (gradientowi funkcji celu);
- ▶ *random\_edge* vs *uniform\_random*
  - ▶ wybór losowy krawędzi/zmiennej (prawdopodobieństwo jednostajne)
- ▶ *poisson\_modulo*

# Analiza wyników

Zależności między kolejnymi parami metod porównane z metodami losowymi (w nawiasach podajemy średnią liczbę kroków; dla metod losowych **uniform\_random** (8.7), **random\_edge** (8.92), **poisson\_modulo** (8.87) użyliśmy średniej z kilku prób):

- ▶ metoda **largest\_coefficient** (5.36) wypadła lepiej niż metody losowe; metoda **smallest\_coefficient** (9.71) radzi sobie gorzej
- ▶ metoda **largest\_increase** (5.71) wypadła lepiej niż metody losowe; metoda **smallest\_increase** (9.5) radzi sobie gorzej
- ▶ nie ma większych różnic między metodami **lexicographical\_max** (8.64), **lexicographical\_min** (8.64) a rezultatami metod losowych
- ▶ metoda **steepest\_edge** (8.07) wypadła lepiej niż metody losowe; **flattest\_edge** (10.57) wypadła gorzej

# Wnioski

- ▶ metody **largest\_coefficient**, **largest\_increase** oraz **steepest\_edge** dają lepsze rezultaty niż metody losowe
- ▶ metody **smallest\_coefficient**, **smallest\_increase** oraz **flattest\_edge** dają rezultaty znacznie gorsze
- ▶ pozostałe metody dają podobne, średnio dobre wyniki

## Podsumowanie

**Najlepsze strategie:** wybór zmiennej o największym współczynniku funkcji celu, wybór kierunku o największym jej wzroście lub wzdłuż jej gradientu.

# Bluff - Projekt 2

Mateusz Doliński, Katarzyna Głowacka, Michał Kozyra

Optymalizacja I - rok 2016/2017

21.06.2017

# Nasze zadanie

- ▶ znaleźć strategię optymalną w grze Bluff:
  - ▶ potraktować tę grę jako grę dwuosobową o sumie zerowej
  - ▶ naturalną reprezentacją jest drzewo gry
  - ▶ cel: uniknąć operowania macierzą gry w postaci normalnej



## Podójście do problemu

Spojrzelismy na sekwencje ruchów obu graczy, które uwzględniliśmy w macierzy  $M$ , której wiersze i kolumny odpowiadają wspomnianym sekwencjom, a nie strategiom czystym zawodników.

### Macierz sekwencji $M$

- ▶ elementy to wartości oczekiwane wypłaty w momencie wykonywania ruchów przez graczy lub zera
- ▶ macierz rzadka
- ▶ ma  $2^{20}$  elementów, a jedynie  $2^8$  z nich jest odpowiednikiem liści w drzewie gry

Przez  $x$  oznaczyliśmy wektor sekwencji ruchów gracza pierwszego, a przez  $y$  - drugiego. Przedmiotem naszego zainteresowania była zatem funkcja celu postaci  $x^T M y$ .

# Kodowanie wierzchołków

Dany wierzchołek kodowaliśmy stringiem wyznaczającym ciąg sekwencji przebiegu gry do tego momentu.

W naszym słowniku:  $a = (1, 1)$ ,  $b = (1, 2)$ , ...,  $h = (2, 4)$ ,  $i = \text{blef}$ .

Zmiennymi decyzyjnymi określiliśmy prawdopodobieństwo bycia w danym wierzchołku. Suma prawdopodobieństw w  $k$ -tym ruchu danego gracza jest równa prawdopodobieństwu znalezienia się w wierzchołku będącym w ostatnim ruchu.

# Problem liniowy

- ▶ funkcja celu jest postaci  $x^T My$
- ▶ rozwiązujemy problem z perspektywy gracza drugiego
- ▶ traktujemy wektor  $x$  jako ustalony
- ▶ minimalizacja oczekiwanej wypłaty gracza 1 - funkcji celu przy warunkach określających zmienną  $y$
- ▶ rozwiązujemy równoważny problem dualny, w którym zmienne  $y$  zostały zastąpione przez sztuczne zmienne  $z$ , a współrzędne wektora  $x$  traktujemy jako parametry
- ▶ znalezienie optymalnego rozwiązania polega na uzmiennieniu wektora  $x$ .

# Spy Union - Projekt 3

Mateusz Doliński, Katarzyna Głowacka, Michał Kozyra

Optymalizacja I - rok 2016/2017

21.06.2017

# Nasze zadanie

- ▶ rozwiązanie problemu Spy Union przy dwóch hierarchiach pracowników zadanych w postaci drzew (WSA i Union)
- ▶ określenie, ilu i których pracowników można zwolnić przy danych minimalnych liczbach pracowników w poszczególnych departamentach
- ▶ celem jest uzyskanie jak najmniejszej możliwej wciąż funkcjonującej struktury organizacji i związku zawodowego

# Dane

## ► INPUT

Przykładowe dane wejściowe:

5				
1	0	1	2	
2	0	1	2	
2	1	2	0	
2	1	0	1	
1	3	0	0	

Liczba w pierwszym wierszu (5) oznacza całkowitą liczbę pracowników.

# Interpretacja kolejnych danych

Table: Przykładowy input

<b>ID pracownika</b>	<b>ID przełożonego WSA</b>	<b>ID przełożonego Union</b>	<b>Minimalna liczba podwładnych WSA</b>	<b>Minimalna liczba podwładnych Union</b>
<b>0</b>	1	0	1	2
<b>1</b>	2	0	1	2
<b>2</b>	2	1	2	0
<b>3</b>	2	1	0	1
<b>4</b>	1	3	0	0

## ► OUTPUT

Dane wyjściowe to maksymalna liczba pracowników, których można zwolnić, aby podane struktury nie zostały zaburzone oraz ich numery. Dla wyżej podanych danych wejściowych dostajemy:

2

4 2



## 3-etapowe podejście do problemu

- ▶ funkcja **fill** - parsowanie danych wejściowych i konwertowanie ich na dwa drzewa implementowane przy pomocy słowników oraz dwie listy z minimalną liczbą pracowników w każdym departamencie w obu strukturach
- ▶ funkcja **department** - dla zadanego drzewa tworzy słownik niezbędny do utworzenia warunków ograniczających dla zadanego problemu liniowego; zaimplementowany algorytm pozwala na otrzymanie wszystkich warunków przy jednokrotnym przeszukaniu całej struktury danych
- ▶ funkcja **solve\_problem** - wykorzystanie przygotowanych słowników do stworzenia oraz rozwiązywania zadanego problemu przy pomocy klasy `MixedIntegerLinearProgram`

Table: Zwolnieni pracownicy

Numer testu	Liczba pracowników	Liczba zwolnionych
0	5	2
1	20	9
2	100	53
3	200	115
4	500	302
5	1000	585
6	2000	1174
7	5000	2754
8	10000	5761
9	20000	11492
10	50000	26428